

Laboratorio 3. Deep Learning. Reconocimiento de Lenguaje de Señas ASL

Informe final

Grupo: Erick Guerra, Fabián Morales, Olivier Viau
10 de agosto de 2026

1. Resumen del análisis exploratorio

El dataset ASL Alphabet contiene 87,000 imágenes de 200x200 píxeles, repartidas en 29 clases balanceadas: las 26 letras del alfabeto más las clases space, delete y nothing. Todas las imágenes están en formato JPG y en color. Al revisar varias muestras de una misma clase se notó que el fondo y la iluminación se mantienen consistentes dentro del dataset. El análisis también identificó grupos de letras que se confunden visualmente por tener formas de mano parecidas: M, N y S por los puños cerrados, U, V y R por los dedos extendidos y cruzados, K y P por depender más de la orientación de la mano que de la forma de los dedos, y G y H por la posición similar de los dedos índice y medio.

2. Preprocesamiento

Para trabajar con un volumen manejable de datos se tomó una submuestra de 600 imágenes por clase, repartida entre entrenamiento, validación y prueba, manteniendo el balance entre clases. Las imágenes se redujeron de 200x200 a 64x64 píxeles y se normalizaron a valores entre 0 y 1. También se probó un filtro de suavizado sobre las imágenes y se construyó un pipeline de carga con tf.data para alimentar los modelos de forma eficiente durante el entrenamiento.

3. Modelos entrenados y resultados

Se entrenaron tres tipos de modelos sobre el mismo conjunto de datos: una red convolucional, CNN, en tres variantes, una red totalmente conectada, MLP, y un Random Forest en dos configuraciones. Los resultados sobre las 2,610 imágenes de prueba, nunca vistas durante el entrenamiento, fueron los siguientes.

Modelo	Accuracy en test	F1 macro en test
CNN base	95.9%	95.9%
Random Forest	96.5%	96.5%
MLP	78.9%	78.7%

El Random Forest obtuvo el mejor resultado en este dataset, seguido muy de cerca por la CNN base. El MLP quedó muy por debajo de los otros dos porque recibe la imagen aplanada en una fila de números y pierde la relación espacial entre píxeles vecinos, algo que sí aprovechan las convoluciones. Además se probó aplicar aumento de datos, image augmentation, sobre la CNN base: en las mismas 10 épocas de entrenamiento el resultado fue menor, 91.4% de accuracy en test contra 96.2% sin aumento, porque el modelo necesita más tiempo de entrenamiento para aprender de versiones

rotadas, trasladadas y con cambios de brillo de cada imagen. La curva de esa versión todavía estaba subiendo al terminar las 10 épocas, lo que sugiere que con más tiempo de entrenamiento alcanzaría o superaría a la versión sin aumento.

4. Del dataset original a fotos reales

La comparación anterior, hecha sobre imágenes que vienen de la misma fuente que el entrenamiento, se puso a prueba con 15 fotos propias del equipo, tomadas con cámaras, fondos y manos distintas a las del dataset original. Ahí los resultados se invirtieron por completo: el Random Forest, ganador del dataset original, no acertó ninguna de las 15 fotos y siempre predijo la clase nothing. La CNN base, que había quedado en segundo lugar, acertó 3 de 15. Ninguno de los dos modelos generaliza bien a condiciones nuevas, pero la CNN se defiende relativamente mejor porque aprende formas y bordes en vez de memorizar la posición de los píxeles, tal como se anticipó en la comparación de modelos y se explica con más detalle en la siguiente sección.

5. Reflexión sobre accesibilidad y sesgo

El dataset de ASL Alphabet usado en este laboratorio tiene una limitación importante para pensar en un producto real como SignBridge: las 87,000 imágenes de entrenamiento vienen de una sola persona, con el mismo fondo, la misma cámara y una iluminación controlada. El punto anterior mostró las consecuencias concretas de esa limitación. El Random Forest, que había quedado primero en la comparación sobre el dataset original con 96.5% de accuracy, cayó a 0 de 15 fotos correctas al probarlo con las manos del equipo, prediciendo siempre la clase nothing sin importar la letra mostrada. La CNN base, que había quedado en segundo lugar con 95.9%, también falló la mayoría de las fotos, pero acertó 3 de 15.

5.1 De dónde viene el sesgo

El Random Forest aprendió a partir de la posición fija de los píxeles, no de la forma de la mano en sí. Como el fondo, el encuadre y la persona casi no cambian dentro del dataset original, el modelo pudo llegar a una accuracy alta sin aprender realmente a reconocer una seña, le bastó con memorizar que ciertas posiciones de píxel suelen tener cierto color para cada clase. En cuanto cambian el fondo, la cámara o quién hace la seña, ese atajo deja de funcionar. La CNN, al aprender filtros que buscan bordes y formas sin importar en qué parte de la imagen aparecen, conserva algo más de capacidad de generalizar, aunque tampoco es robusta.

5.2 Implicaciones de accesibilidad

Un sistema como SignBridge existe para ayudar a personas sordas o con dificultades auditivas a comunicarse. Si el modelo solo reconoce señas hechas por una persona, con un tono de piel, un tamaño de mano y un fondo específicos, el grupo que más necesita la herramienta es justo el que corre más riesgo de que el sistema le falle. El dataset usado en este laboratorio no incluye variación de tono de piel, edad ni tamaño de mano, y tampoco incluye condiciones físicas distintas, como manos con artritis, con dedos amputados o con prótesis. Tampoco varía la cámara ni la calidad de conexión, factores que sí cambian mucho entre usuarios reales. Si el conjunto de entrenamiento de un producto real quedara sesgado hacia un tipo de usuario en particular, el modelo podría funcionar

peor, o fallar directamente, para el resto de la población, sin que ese problema se note en una accuracy medida sobre un dataset igual de homogéneo.

El hallazgo anterior deja una lección concreta sobre esto: ganar la comparación en un benchmark parejo no dice nada sobre qué tan confiable es un modelo fuera de ese benchmark. El Random Forest ganó el benchmark original y fue el peor en condiciones reales, justo porque su ventaja dependía de una uniformidad que no existe fuera del dataset.

5.3 Recomendaciones del equipo

Problema detectado	Recomendación
Dataset con una sola persona y un solo fondo	Recolectar fotos de múltiples personas, tonos de piel, edades, fondos y cámaras antes de entrenar el modelo final
El Random Forest depende de la posición fija de los píxeles	Priorizar arquitecturas como la CNN, que aprenden formas y no posiciones fijas, para un producto que debe funcionar con fondos distintos
La accuracy en un dataset homogéneo no predice el desempeño real	Validar el modelo con un conjunto recolectado por separado, con personas y condiciones distintas a las del entrenamiento
No se probaron manos con diferencias físicas	Incluir de forma deliberada personas con distintas formas y movilidad de mano en las pruebas, para que el producto no excluya justo a quienes más podrían necesitarlo

6. Conclusión general y recomendación del equipo

La accuracy sobre el dataset de Kaggle no fue un buen predictor del desempeño del modelo en condiciones reales. El modelo que ganó la comparación en el laboratorio, Random Forest, resultó ser el que peor funcionó con fotos nuevas, mientras que la CNN, aunque también tuvo un desempeño bajo, se mantuvo como la opción más confiable de las dos para un escenario fuera del dataset de entrenamiento. Para un producto real como SignBridge, el equipo recomienda partir de una arquitectura convolucional en vez de Random Forest, incorporar aumento de datos con más épocas de entrenamiento de las usadas en este laboratorio, y sobre todo, ampliar el conjunto de entrenamiento con personas, fondos, cámaras y condiciones físicas distintas antes de considerar el modelo listo para usuarios reales.